CSA 与CSA2

0. 统一符号

- B：batch size;
- T：当前序列长度;
- H：主干hidden 维度，且$H = n_h d_h$;
- n_h：attention 头数;
- d_h：每个head 的维度;
- b：压缩块大小，$C = \lceil T/b \rceil$;
- b_1, b_2：粗压缩块、细压缩块大小;
- $C_1 = \lceil T/b_1 \rceil$, $C_2 = \lceil T/b_2 \rceil$, $g = b_1/b_2$;
- K：top-k 压缩槽数;
- K_1, K_2：粗top-k、细top-k;
- W：局部窗口长度;
- d_i：indexer 低维维度。

因果压缩与mask 约定

为避免当前块包含未来信息，本文采用如下约定：

- 完整历史块可以整块压缩;
- 当前块（包含查询token 的块）必须使用**块内因果前缀压缩**，即只压缩到当前token，不得使用整块表示;
- 若实现采用严格整块压缩，则必须把当前块从可见集合中mask 掉，并对$t < b$（或两级中的$t < b_2$）提供自身/局部窗口回退;
- TopK 前先把不可见块置为$-\infty$；TopK 可能返回无效/pad 索引，后续attention 必须用mask 把无效槽置为$-\infty$;
- 当T 不能被块大小整除时，最后一块不完整，需要按实际长度压缩或mask/clamp。

1 CSA：单级压缩稀疏注意力

【DeepSeek-V4 配置参数】 $B = 1$, $T = 4096$, $H = 4096$, $n_h = 32$, $d_h = 128$, $d_i = 128$, $b = 64$, $C = 64$, $K = 16$。

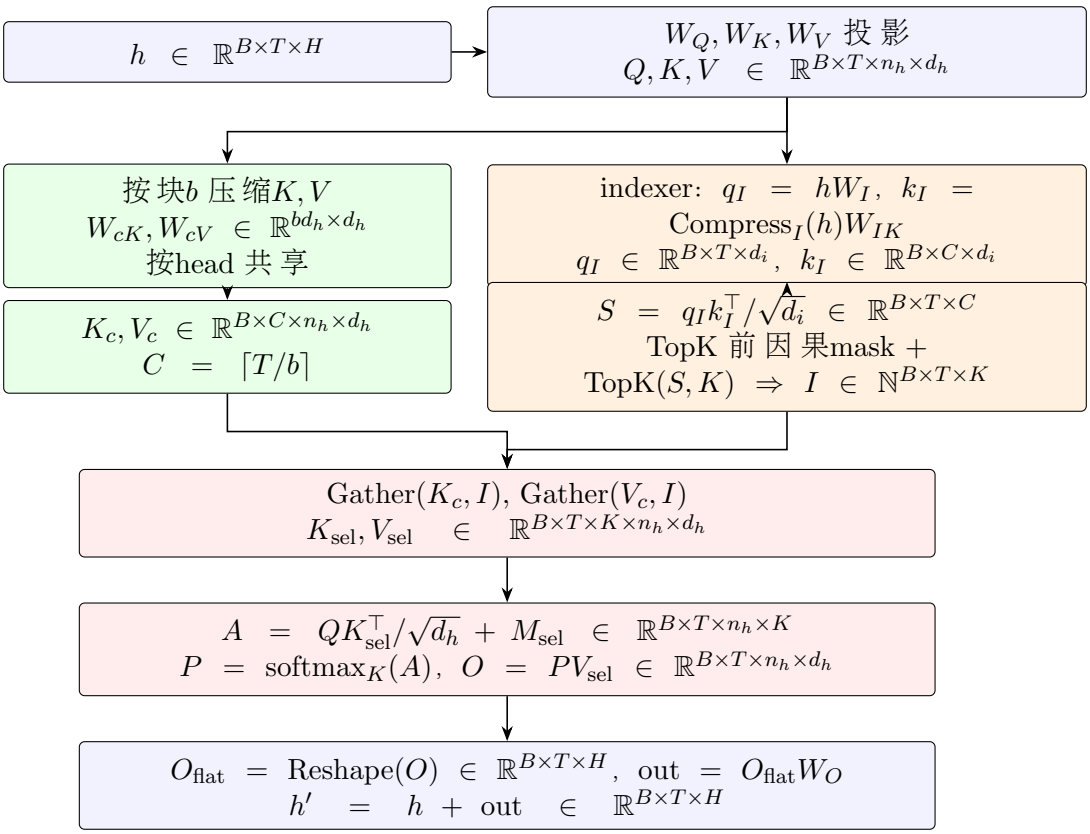


Figure 1: CSA 单级压缩稀疏注意力全流程。

1.1 全流程总览（图）

1.2 步骤1：Q/K/V 投影与形状重塑

【原理与细节】 输入$h \in \mathbb{R}^{1\times 4096\times 4096}$，通过三个投影矩阵$W_Q, W_K, W_V \in \mathbb{R}^{4096\times 4096}$。输出$Q, K, V$的shape 均为$[1, 4096, 32, 128]$。**内部视角：** 实际上这里发生了一步reshape，4096 的最后一维被拆解为$n_h = 32$ 个头，每个头维度$d_h = 128$。即$H = 32 \times 128 = 4096$。

1.3 步骤2：块压缩（粗粒度下采样）

【原理与细节】 序列长度$T = 4096$，块大小$b = 64$。$C = 4096/64 = 64$。将序列维按每64 个token切分：K 变成$[1, 64, 64, 32, 128]$（块数× 块内token × head × d_h）。对于每个完整历史块，使用共享的压缩权重$W_{cK} \in \mathbb{R}^{64d_h\times d_h}$ 做映射；若按每个head 独立压缩，则权重写成$\mathbb{R}^{n_h\times 64d_h\times d_h}$。压缩后得到$K_c \in \mathbb{R}^{1\times 64\times 32\times 128}$（从4096 个token 压缩成了64 个槽位）。

因果前缀压缩： 对查询token t，完整历史块$j < \lfloor t/b \rfloor$ 可用整块压缩表示；当前块$j = \lfloor t/b \rfloor$ 必须使用块内因果前缀压缩，即只压缩该块中位置$\le t$ 的token。若实现采用严格整块压缩，则必须把当前块mask 掉，并对$t < b$ 提供自身/局部回退。

1.4 步骤3：Indexer 打分与因果掩码

【原理与细节】 计算低维查询$q_I = hW_I \in \mathbb{R}^{1\times 4096\times 128}$，压缩键$k_I = \mathrm{Compress}_I(h)W_{IK} \in \mathbb{R}^{1\times 64\times 128}$。**点积打分：** 做矩阵乘法$S = q_I k_I^\top$。张量的广播机制会把$q_I$ 的所有token 与k_I 的所有块做点积。结果$S \in \mathbb{R}^{1\times 4096\times 64}$。

因果掩码细节： 在因果前缀压缩约定下，token t 可见的块索引满足

$$j \le \left\lfloor \frac{t}{b} \right\rfloor,$$

其中$j < \lfloor t/b \rfloor$ 是完整历史块，$j = \lfloor t/b \rfloor$ 是当前前缀块。所有$j > \lfloor t/b \rfloor$ 的得分在TopK 前置为$-\infty$。

对于第$t = 100$ 个token，$b = 64$，有$\lfloor 100/64 \rfloor = 1$。因此可见块0（完整块0–63）和块1（仅前缀64–100），不能看块2 到63。块1 不得使用整块64–127 的压缩表示，否则会泄漏未来信息。若实现采用严格整块压缩，则$t = 100$ 只能看块0，并且$t < 64$ 需要自身/局部回退。

TopK： 在mask 后的一行里取前$K = 16$ 个最大的值的索引，最后索引矩阵$I \in \mathbb{N}^{1\times 4096\times 16}$。若可见块数少于$K$，TopK 会返回无效/pad 索引，后续attention 必须将这些槽mask 掉。

1.5 步骤4：Gather 与稀疏Attention（维度对齐与mask）

【原理与细节】 根据I 提取KV：$K_{\text{sel}} = \text{Gather}(K_c, I)$。$K_c$ 是$[1, 64, 32, 128]$，根据I 的最后一维取值，得到$K_{\text{sel}} \in \mathbb{R}^{1\times 4096\times 16\times 32\times 128}$。（把选中的16 个块展开）。**计算Attention：** 对每个token t，取$Q_t \in \mathbb{R}^{32\times 128}$，与$K_{\text{sel},t} \in \mathbb{R}^{16\times 32\times 128}$ 广播计算。得到的分数$A_t \in \mathbb{R}^{32\times 16}$。拼起来整体$A \in \mathbb{R}^{1\times 4096\times 32\times 16}$。

Attention mask： 显式加入

$$A = QK_{\text{sel}}^{\top}/\sqrt{d_h} + M_{\text{sel}}, \qquad M_{\text{sel}} \in \{0, -\infty\}^{B\times T\times n_h\times K},$$

其中无效TopK 槽置为$-\infty$；若TopK 前未做因果mask，则因果违规槽也需在此处置为$-\infty$。然后

$$P = \text{softmax}_K(A), \qquad O = PV_{\text{sel}} \in \mathbb{R}^{B\times T\times n_h\times d_h}.$$

Softmax 后与V_{sel} 加权求和，输出$O \in \mathbb{R}^{1\times 4096\times 32\times 128}$。

1.6 步骤5：Flatten 与残差

【原理与细节】 最后一步，将O 的$n_h \times d_h$ 展平：$O_{\text{flat}} \in \mathbb{R}^{1\times 4096\times 4096}$。乘上输出投影矩阵$W_O \in \mathbb{R}^{4096\times 4096}$ 并加回主干h，得到$h' \in \mathbb{R}^{1\times 4096\times 4096}$。

2 CSA2：两级压缩稀疏注意力

【DeepSeek-V4.1 Flash 配置】 $B = 1,\ T = 4096,\ H = 4096,\ n_h = 32,\ d_h = 128,\ d_i = 128,\ b_1 = 64,\ b_2 = 16,\ C_1 = 64,\ C_2 = 256,\ g = 4,\ K_1 = 8,\ K_2 = 16,\ W = 128$。

2.1 全流程总览（图）

2.2 步骤1 & 2：粗压缩与粗筛选

【原理与细节】 $b_1 = 64$，$C_1 = 64$。粗筛选$K_1 = 8$。粗indexer 构造为

$$q_{I1} = hW_{I1} \in \mathbb{R}^{B\times T\times d_i}, \qquad k_{I1} = \text{Compress}_{I1}(h)W_{IK1} \in \mathbb{R}^{B\times C_1\times d_i}.$$

点积得到

$$S_1 = q_{I1}k_{I1}^{\top}/\sqrt{d_i} \in \mathbb{R}^{1\times 4096\times 64}.$$

因果mask： 对$j > \lfloor t/b_1 \rfloor$ 的粗块在TopK 前置为$-\infty$；当前粗块$j = \lfloor t/b_1 \rfloor$ 使用块内因果前缀压缩。每个token 选出得分最高的8 个有效粗块索引

$$I_1 \in \mathbb{N}^{1\times 4096\times 8}.$$

若可见粗块数少于K_1，TopK 返回的无效/pad 索引需在后续候选展开和attention 中过滤或mask。

粗indexer 使用独立的低维压缩键，不产生进入attention 的V_{c1}；因此不存在冗余的V_{c1} 消费者。

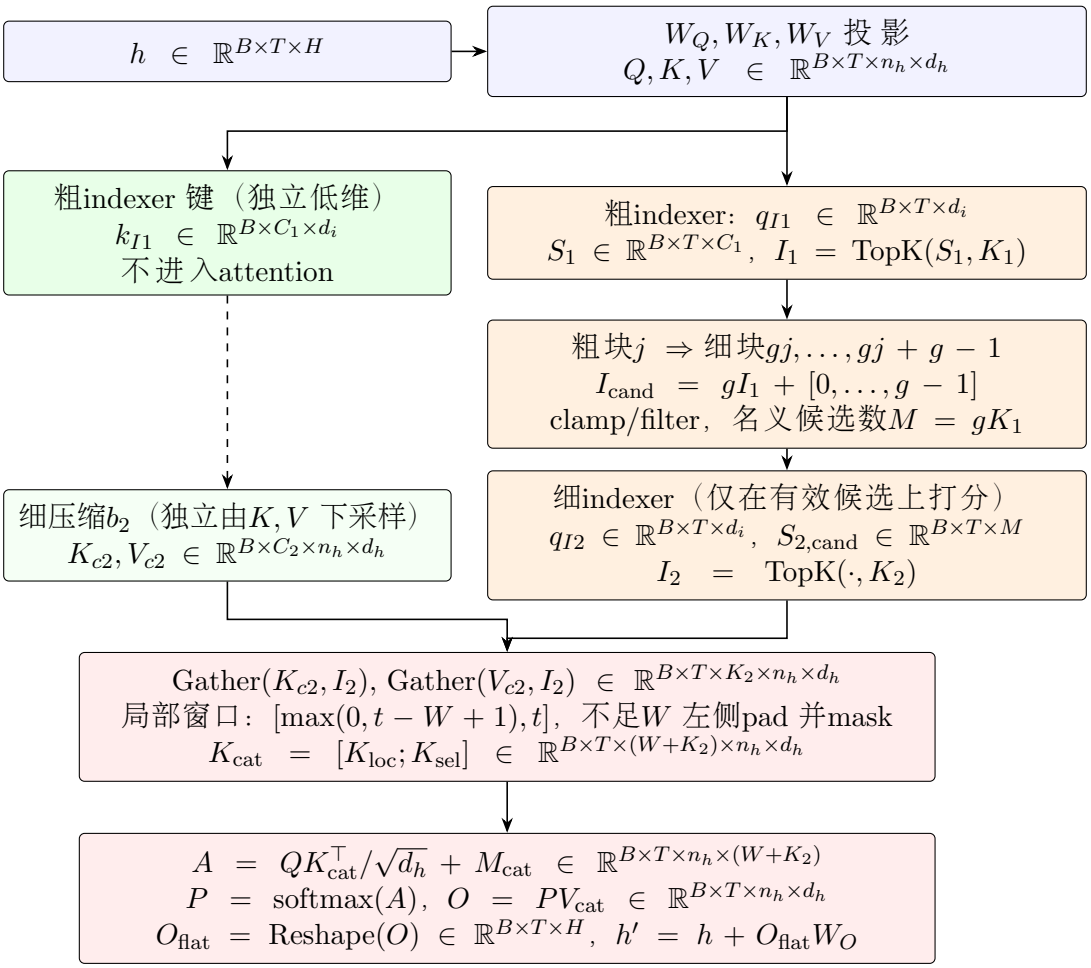


Figure 2: CSA2 两级压缩稀疏注意力全流程（Flash 版）。

2.3 步骤3：候选细块展开（索引映射、clamp 与mask）

【原理与细节】 细块$b_2 = 16$，$C_2 = 4096/16 = 256$。$g = 64/16 = 4$。粗块j 覆盖细块$4j$ 到$4j+3$。

具体计算： 假设某个token 的粗索引$I_1 = [1, 5, 10, \dots]$。把I_1 乘上$g = 4$，得到基索引$[4, 20, 40, \dots]$，然后加上偏移量$[0, 1, 2, 3]$（广播），得到名义候选细块集合

$$I_{\text{cand}} = gI_1 + [0, 1, 2, 3], \qquad I_{\text{cand}} \in \mathbb{N}^{1\times 4096\times 32}.$$

实现时需：

- 将I_{cand} clamp 到$[0, C_2 - 1]$；
- 对无效粗索引产生的候选进行过滤或pad；
- 对细块$k > \lfloor t/b_2 \rfloor$ 的候选在细打分前置为$-\infty$；
- $M = gK_1 = 32$ 是名义候选长度，有效候选数可能少于M。

2.4 步骤4：细粒度打分与Gather

【原理与细节】 细indexer 构造为

$$q_{I2} = hW_{I2} \in \mathbb{R}^{B\times T\times d_i}, \qquad k_{I2} = \text{Compress}_{I2}(h)W_{IK2} \in \mathbb{R}^{B\times C_2\times d_i}.$$

只在候选集合上打分：

$$S_{2,\text{cand}} = q_{I2}\, k_{I2}[I_{\text{cand}}]^\top / \sqrt{d_i} \in \mathbb{R}^{1\times 4096\times 32}.$$

对无效候选和因果违规候选置$-\infty$ 后，只在这32 个候选里挑出$K_2 = 16$ 个，得到全局细索引

$$I_2 \in \mathbb{N}^{1\times 4096\times 16}.$$

Gather： 细压缩$K_{c2} \in \mathbb{R}^{1\times 256\times 32\times 128}$，用$I_2$ 提取得到

$$K_{\text{sel}} \in \mathbb{R}^{1\times 4096\times 16\times 32\times 128}, \qquad V_{\text{sel}} \in \mathbb{R}^{1\times 4096\times 16\times 32\times 128}.$$

当前细块若被选中，也必须使用块内因果前缀压缩；TopK 的无效槽在attention 中mask。

2.5 步骤5：局部窗口的精细拼接

【原理与细节】 局部窗口$W = 128$。对于token t，取序列中

$$[\max(0, t - W + 1),\, t]$$

这最多128 个原始token 的KV。若$t < W - 1$，左侧不足W 的位置需要padding 并在attention 中mask。K_{loc} 的shape 为$[1, 4096, 128, 32, 128]$。

拼接操作： 在倒数第3 维（即K_2 所在的那一维）做concat：

$$[1, 4096, 128, 32, 128] \text{ 与 } [1, 4096, 16, 32, 128] \longrightarrow [1, 4096, 144, 32, 128].$$

这一步非常关键：**局部窗口保证了即便粗/细indexer 全部失效，token 依然能看到自己附近的上下文。** 局部窗口本身不含未来token，不需要未来因果掩码；但左侧padding 位置必须mask。

2.6 步骤6：Attention 与输出

【原理与细节】 Q 为$[1, 4096, 32, 128]$，K_{cat} 为$[1, 4096, 144, 32, 128]$。点积计算

$$A = QK_{\text{cat}}^{\top}/\sqrt{d_h} + M_{\text{cat}}, \qquad M_{\text{cat}} \in \{0, -\infty\}^{B\times T\times n_h\times (W+K_2)}.$$

其中局部窗口左侧padding 位置、无效TopK 槽置为$-\infty$；若TopK 前已经完成因果mask，则稀疏槽无需重复因果mask，但统一构造M_{cat} 更安全。然后

$$P = \text{softmax}(A), \qquad O = PV_{\text{cat}} \in \mathbb{R}^{B\times T\times n_h\times d_h}.$$

展平后$O_{\text{flat}} \in \mathbb{R}^{B\times T\times H}$，残差加回:

$$h' = h + O_{\text{flat}}W_O \in \mathbb{R}^{B\times T\times H}.$$