DeepSeek V4 CSA 与V4.1 Flash CSA2 的压缩机制与结构流

1 背景

DeepSeek V4 系列为了降低长上下文（Long-context）下的KV Cache 占用与注意力计算量，采用了压缩稀疏注意力（Compressed Sparse Attention, CSA）。CSA 的核心思想分为两步：先对长序列进行**压缩（Compression）**，再在压缩后的池子中进行**稀疏检索（Top-k）**。

本文档详细拆解V4 的CSA（重叠压缩）与V4.1 Flash 的CSA2（无重叠、跨层共享）的具体压缩过程及张量Shape 变化。

2 压缩过程详解：重叠vs 无重叠

1. V4 CSA 的"重叠压缩" (Overlapping Compression). 为了在压缩的同时不丢失边界信息，V4 采用了滑动窗口重叠池化。

- **窗口与步长**：窗口大小$W = 8$，滑动步长$S = 4$。
- **计算逻辑**：每4 个Token 生成一个压缩条目，但每个条目实际上融合了相邻8 个Token 的信息。具体计算时，对窗口内的8 个Token 进行**带可学习权重的加权池化**（并非简单的平均池化）。
- **信息保留**：块与块之间有50% 的重叠区，确保局部语义的连续性。

2. V4.1 CSA2 的"无重叠压缩" (Non-overlapping Pooling). CSA2 发现重叠压缩带来的存储和计算开销偏大，转而采用严格的跨步池化。

- **窗口与步长**：窗口大小$W = r$，滑动步长$S = r$（r 为可配置的压缩比，如$r = 2$）。
- **计算逻辑**：严格每r 个相邻Token 池化为1 个共享的潜在向量（Latent Vector）。窗口之间没有任何重叠。
- **跨层弥补**：由于取消了重叠，单层的局部信息表达会变弱，因此CSA2 依赖跨层共享（Full/Reuse 模式）来弥补信息损失。

3 DeepSeek V4 CSA 的整体Shape 流

核心思想. **单**层独立完成"重叠压缩→ 低维索引→ Top-k 筛选→ 核心注意力"。

4 DeepSeek V4.1 Flash CSA2 的整体Shape 流

核心思想. **取**消重叠压缩，引入跨层静态调度与分层索引，以极致压缩KV Cache。通过将层划分为**Full**、**Reindex**、**Reuse** 三种模式实现：Full 层计算压缩KV 与Top-k 索引；Reindex 层**复用压缩KV，但重新计算Top-k**；Reuse 层同时复用压缩KV 与Top-k 索引。

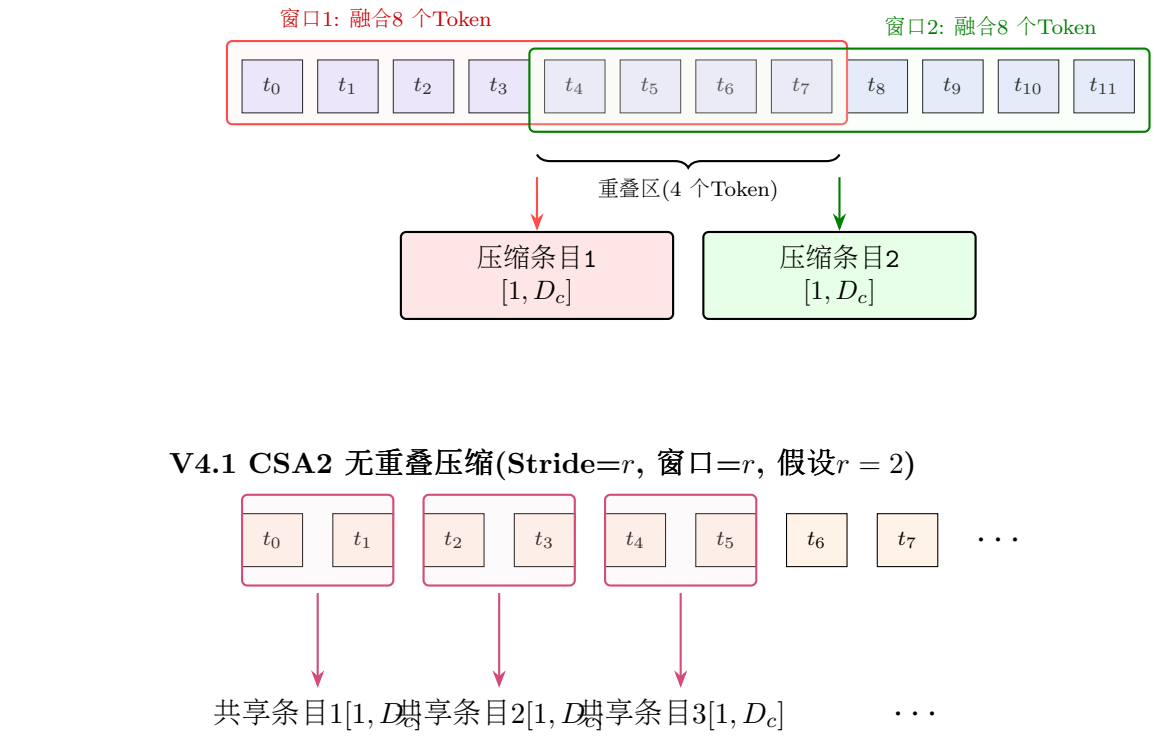


Figure 1: 压缩过程的物理映射：V4 采用重叠窗口（保留边界信息），V4.1 采用无重叠池化（严格降采样r 倍）。

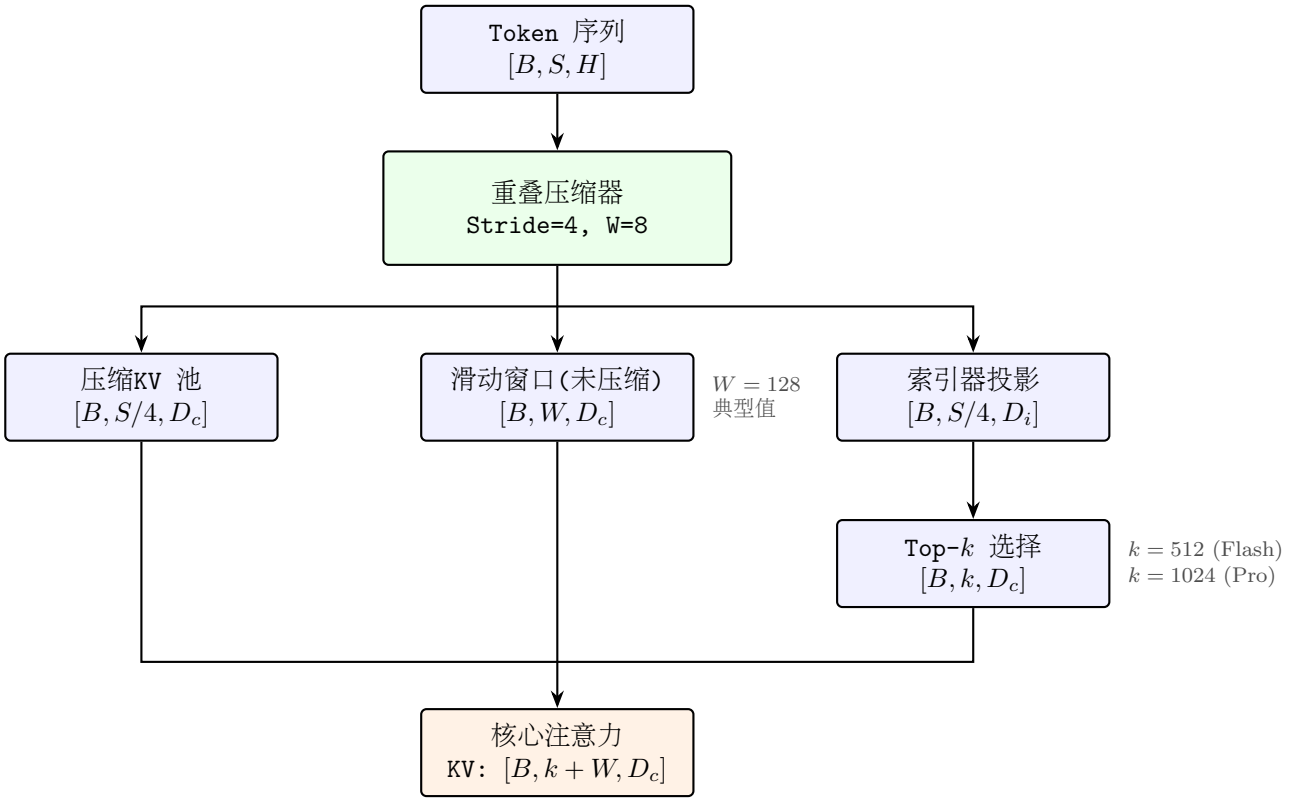
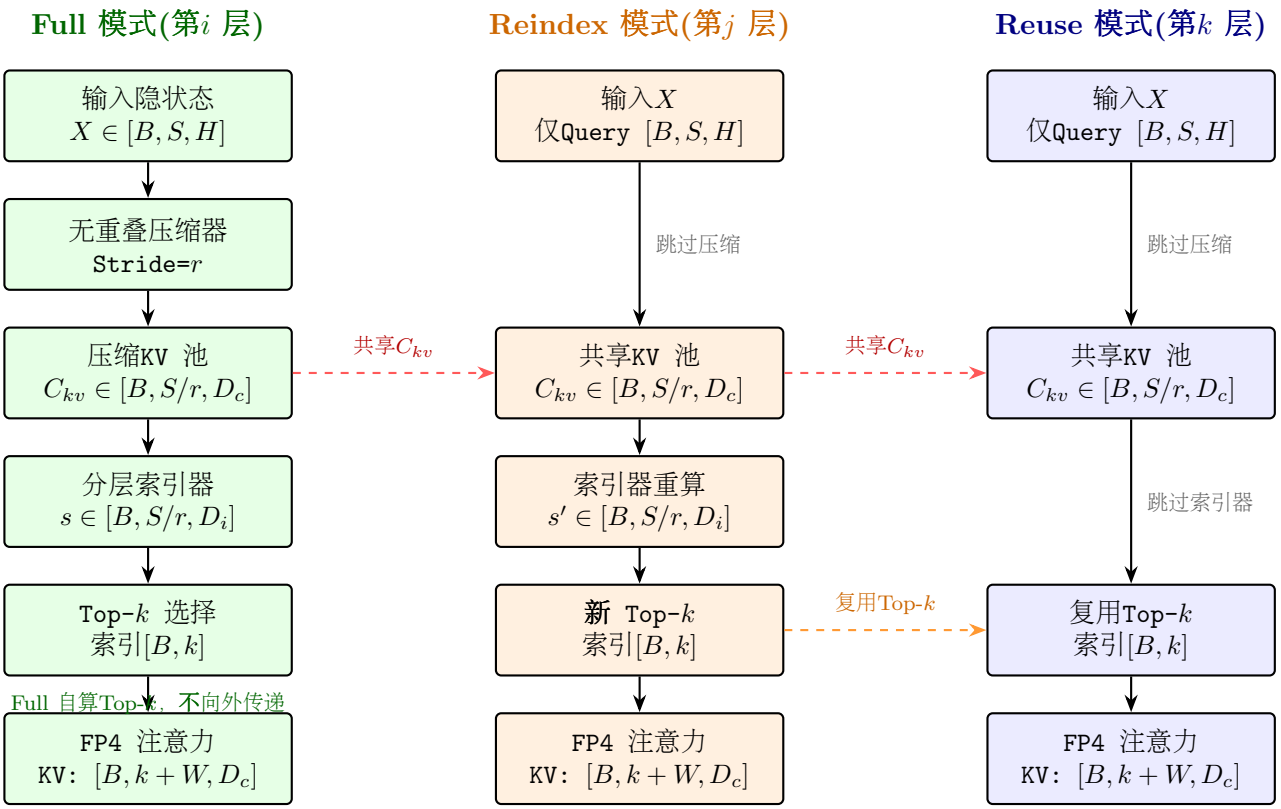


Figure 2: DeepSeek V4 CSA 的Shape 流：单层内完成压缩、索引与Top-k 筛选。



40 层模型中压缩比r 的静态分布

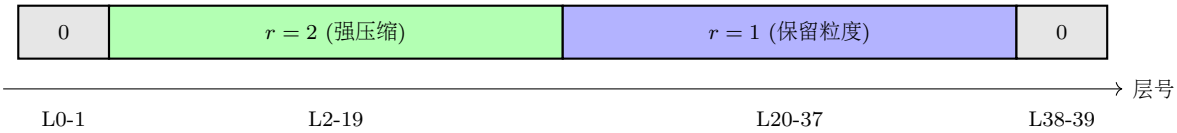


Figure 3: DeepSeek V4.1 Flash CSA2 的三模式Shape 流：左侧Full 层生成压缩池与Top-k 索引；中间Reindex 层复用压缩池但**重新计算** Top-k；右侧Reuse 层复用压缩池与Top-k。底图为40 层静态压缩比分配。

5 核心维度解释与对比

- D_c **(Compressed Dimension)**：压缩池中每个KV 向量的特征维度，通常与模型的主注意力头维度对齐（如512）。
- D_i **(Indexer Dimension)**：索引器打分时使用的低维投影空间（如128）。这是一个“粗筛”维度，用于降低计算开销。
- B, S, H：Batch 大小、序列长度、隐藏维度。
- r：逐层静态压缩比，$r = 0$ 表示该层跳过压缩（保持全分辨率或走SWA），$r = 1$ 表示不降采样但走统一路径，$r = 2$ 表示2 倍降采样。
- k：Top-k 稀疏检索保留的压缩条目数（Flash 取512，Pro 取1024）。
- W：滑动窗口（SWA）长度，典型值128。

Table 1: DeepSeek V4 CSA 与V4.1 Flash CSA2 的结构对比

特性	V4 CSA	V4.1 Flash CSA2
压缩方式	重叠压缩（Stride=4，窗口=8）	无重叠压缩（Stride=r）
压缩比r	固定为4	逐层静态分配（0, 1, 2）
KV 共享	每层独立	跨层共享（Full / Reindex / Reuse）
索引策略	每层独立Top-k 筛选	Full 层自算；Reindex 层**重算**；Reuse 层**复用**
候选池复用	无	Reindex / Reuse 均复用Full 的C_{kv} 池
KV 存储	BF16 / FP8	FP4（E2M1 + E4M3 scale）
注意力KV 形状	$[B, k+W, D_c]$	$[B, k+W, D_c]$